Inove Coding School

Proyecto Final

“Python Analytics”

Alumno:

Valentín Marco Imperio

Profesores:

Johana Rangel

Julián Salinas

Fecha de Entrega:

28/01/2023

Introducción

El objetivo del presente proyecto final es aplicar los conocimientos aprendidos a lo largo del curso *Programador Python*. Particularmente se trabajará con los siguientes conceptos:

- Funciones y variables.
- Ciclos y bucles *for*.
- Listas, Tuplas y Diccionarios.
- Comprensión de Listas.
- Arrays y la librería Numpy.
- Bases de datos.
- SQL ORM con SQL Alchemy.
- Modularización.
- Gráficos con Matplotlib.
- Utilización de las Buenas Prácticas de la Programación.

Dado que el tema elegido es el análisis de un dataset de ventas de calzado internacionales, se explicará el proyecto y su aplicación en el próximo apartado.

Desarrollo

Se explica a continuación en orden cronológico el objetivo de cada función utilizada.

Función read_db()

La misma se utiliza para la limpieza, ordenamiento y lectura de los datos.

```
Producto ID 2152 del país United Kingdom, género
 tamaño 11, precio  $159.00  en la fecha 1/1/2014
Producto ID 2230 del país United States, género Male
 tamaño 11.5, precio  $159.20  en la fecha 1/1/2014
Producto ID 2160 del país Canada, género Male
 tamaño 9.5, precio  $119.20  en la fecha 1/1/2014
Producto ID 2234 del país United States, género Female
 tamaño 9.5, precio  $159.00  en la fecha 1/1/2014
Producto ID 2222 del país United Kingdom, género Female
 tamaño 9, precio  $159.00  en la fecha 1/1/2014
Producto ID 2173 del país United States, género Male
 tamaño 10.5, precio  $159.00  en la fecha 1/1/2014
Producto ID 2200 del país Germany, género Female
 tamaño 9, precio  $179.00  en la fecha 1/2/2014
Producto ID 2238 del país Canada, género Male
 tamaño 10, precio  $169.00  en la fecha 1/2/2014
Producto ID 2191 del país United States, género Male
 tamaño 10.5, precio  $139.00  en la fecha 1/2/2014
Producto ID 2237 del país United Kingdom, género Female
 tamaño 9, precio  $149.00  en la fecha 1/2/2014
```

Figura 1 – *Primeros 10 datos de la tabla Original – Screen Python*

```
Producto ID 2230 del país United States, género Male
 tamaño 11.5, precio  $159.20  en la fecha 1/1/2014
Producto ID 2160 del país Canada, género Male
 tamaño 9.5, precio  $119.20  en la fecha 1/1/2014
Producto ID 2234 del país United States, género Female
 tamaño 9.5, precio  $159.00  en la fecha 1/1/2014
Producto ID 2222 del país United Kingdom, género Female
 tamaño 9, precio  $159.00  en la fecha 1/1/2014
Producto ID 2173 del país United States, género Male
 tamaño 10.5, precio  $159.00  en la fecha 1/1/2014
Producto ID 2200 del país Germany, género Female
 tamaño 9, precio  $179.00  en la fecha 1/2/2014
Producto ID 2238 del país Canada, género Male
 tamaño 10, precio  $169.00  en la fecha 1/2/2014
Producto ID 2191 del país United States, género Male
 tamaño 10.5, precio  $139.00  en la fecha 1/2/2014
Producto ID 2237 del país United Kingdom, género Female
 tamaño 9, precio  $149.00  en la fecha 1/2/2014
Producto ID 2197 del país United States, género Male
 tamaño 10, precio  $129.00  en la fecha 1/2/2014
```

Figura 2 – *Primeros 10 datos de la tabla Filtrada – Screen Python*

Por ejemplo, al comparar la Figura 1 con la Figura 2, se observa que el producto 2152 fue removido por tener un dato faltante en “gender”.

Función paises_unicos()

Esta función sirve para obtener una lista de todos los países en los que se efectuó al menos una venta.

```
En el siguiente array se muestran los países en los que hubo ventas:
['Canada' 'Germany' 'United Kingdom' 'United States']
```

Figura 3 – *Lista de países*

Función ventas_pais()

La misma sirve para obtener un diccionario de todos los países con la cantidad de ventas en dólares.

```
En el siguiente diccionario se muestra el total de ventas por país
{'Canada': 421860.1, 'Germany': 626249.4, 'United States': 839355.1, 'United Kingdom': 250397.3}
```

Figura 4 – Diccionario con v*entas en dólares por país*

Se muestra el resultado obtenido en el siguiente gráfico de tortas.

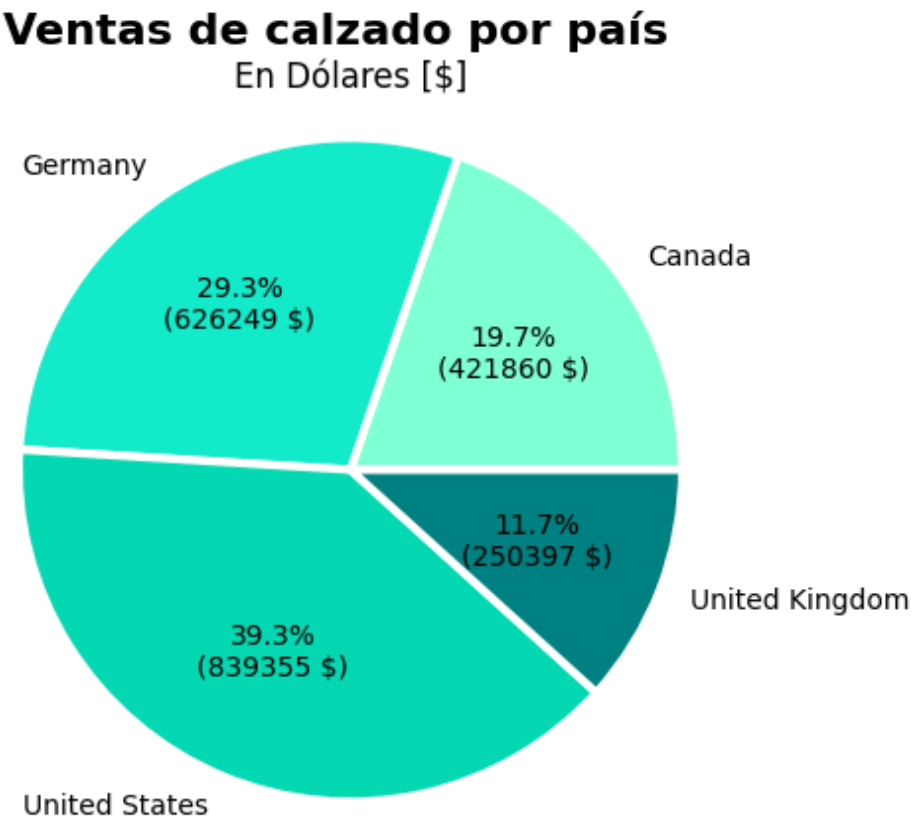

Función calzado_pais()

Esta función sirve para obtener un diccionario del tamaño de calzado más vendido en cada país.

```
En el siguiente diccionario se muestra el tamaño de calzado más vendido en cada país
(array(['10', '10.5', '11', '11.5', '12', '13', '14', '15', '4.5', '5',
       '5.5', '6', '6.5', '7', '7.5', '8', '8.5', '9', '9.5'],
      dtype='<U32'), array([284, 278, 132,  86,  72,  12,  21,  27,   6,   6,   6,  36,  66,
       116, 196, 239, 357, 530, 455], dtype=int64))
```

Figura 4 – *Lista de arrays con el N° de ventas por tamaño de calzado en Canadá*

Se obtienen la cantidad de ventas según el tamaño de calzado para cada país, en este ejemplo se utilizó Canadá. Efectivamente se obtiene que tamaño más comercializado es el calzado N°9, con 530 ventas realizadas.

Luego en la figura 5 se muestran el resultado para cada país:

```
En el siguiente diccionario se muestra el tamaño de calzado más vendido en cada país
{'Canada': '9', 'Germany': '9.5', 'United States': '9.5', 'United Kingdom': '9.5'}
```

Figura 5 – *Diccionario con el N° de calzado más vendido por país*

Se muestra el resultado obtenido en el siguiente gráfico de barras.

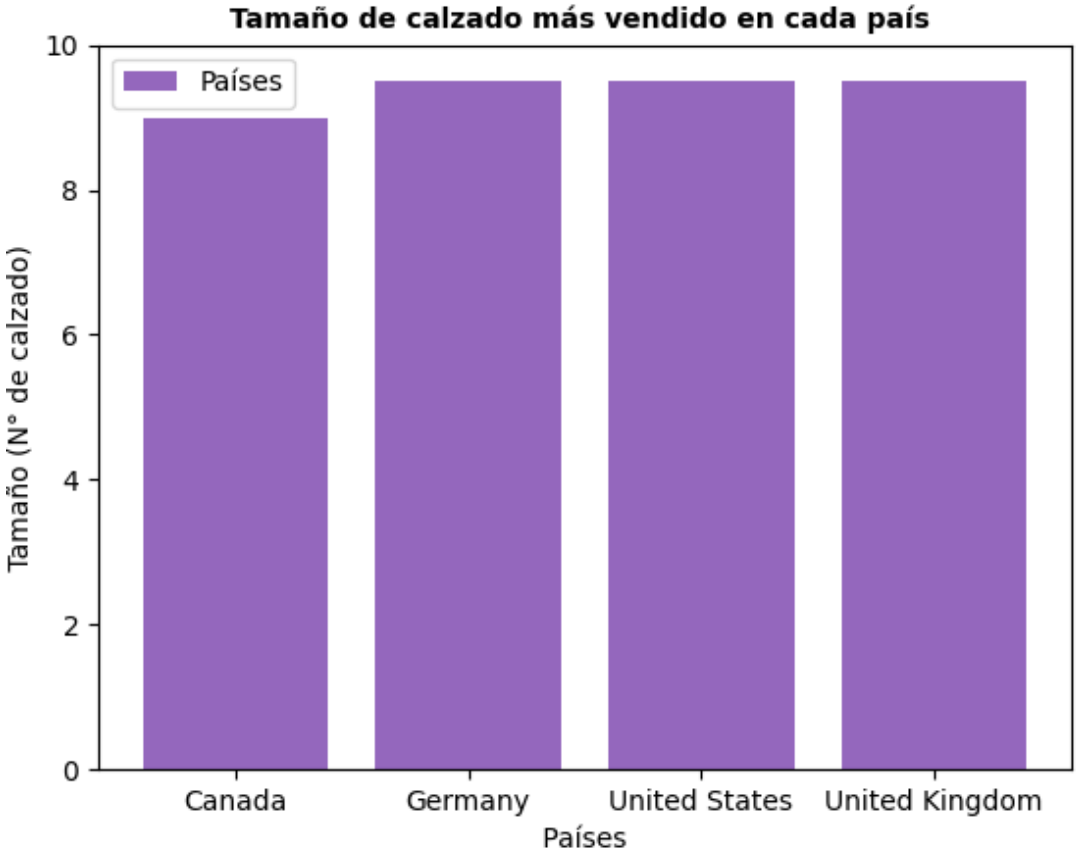

<u>Función ventas_genero_pais()</u>

En esta función el usuario puede elegir un género target y de acuerdo al mismo se muestran las ventas de calzado por país. A continuación, se pueden ver dos ejemplos, para *Female* y para *Male*.

```
En el siguiente diccionario se muestan las ventas para el género Female en cada país
{'Canada': 1108, 'Germany': 1700, 'United States': 2444, 'United Kingdom': 666}
```

Figura 6 – *Diccionario con las ventas de calzado para mujeres en cada país*

```
En el siguiente diccionario se muestan las ventas para el género Male en cada país:
{'Canada': 1791, 'Germany': 2603, 'United States': 3322, 'United Kingdom': 1033}
```

Figura 7 – *Diccionario con las ventas de calzado para hombres en cada país*

Se muestra el resultado obtenido en el siguiente gráfico de tortas.

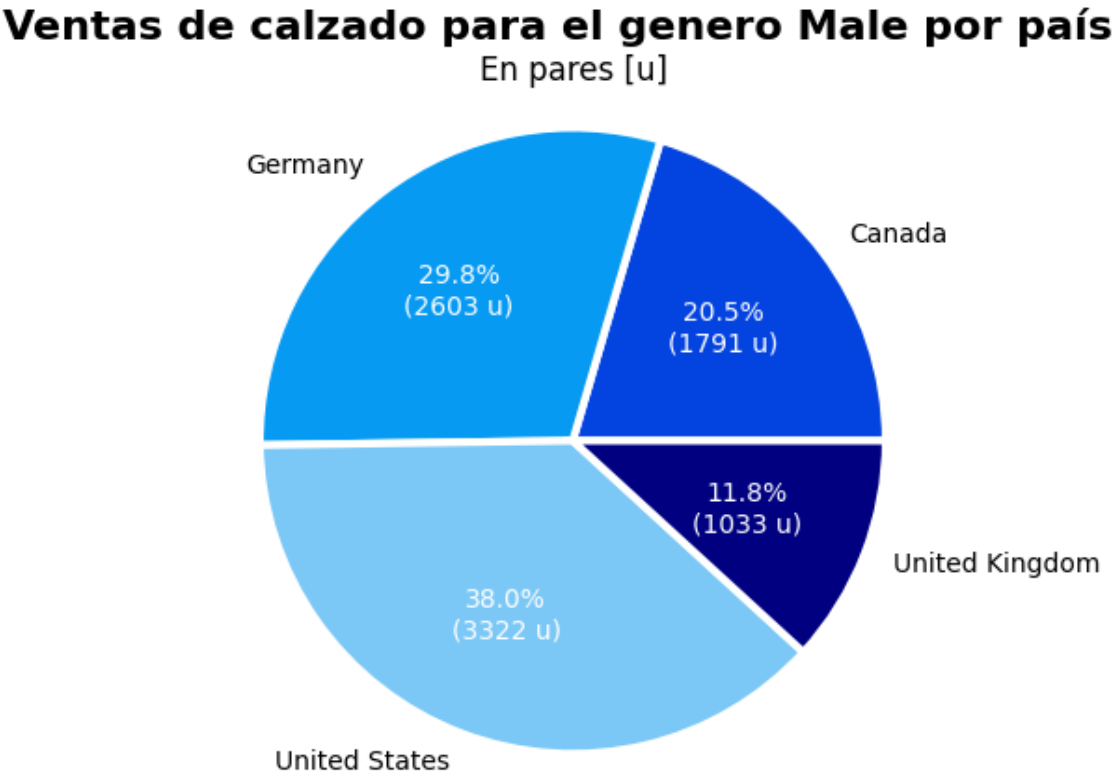

Bonus Track: Gráficos

Se elaboraron distintos gráficos para cada función utilizando la librería *Matplotlib*. Los mismos se encuentran con su función correspondiente dentro de cada apartado.

Anexo: Código

Se adjunta el código utilizado para el llevado a cabo del proyecto correspondiente al archivo main.py y graficos.py

```
##########################################################################

# Proyecto Final - Inove Escuela de Código
# Tema Elegido: Python Analytics

# Alumno: Valentín Imperio.
# Versión: 1.0
# Profesores: Johana Rangel y Julián Salinas.
# Curso: Programador Python.
# Fecha de Entrega: 28/01/2023

# ARCHIVO PRINCIPAL: MAIN.PY

##########################################################################

# DESARROLLO DEL PROYECTO #

#### Librerías utilizadas ###

import numpy as np
import re # Para convertir a float y remover $
import sqlalchemy
from sqlalchemy import Column, Integer, String # Herramientas para crear
la tabla.
from sqlalchemy.ext.declarative import declarative_base # Molde para
tablas de bases de datos.
from sqlalchemy.orm import sessionmaker # Sirve para poder iniciar la
sesión


### Creación del motor (engine) de la base de datos

engine = sqlalchemy.create_engine("sqlite:///ventas_calzados.db")
base = declarative_base()


###### Creación de la Clase Ventas ######
# Para armar la estructura de la tabla dada (visualizador de bases de
datos en
# https://extendsclass.com/sqlite-browser.html) con el ORM de SqlAlchemy
se
# genera la siguiente clase.

class Ventas(base):
```

```
    __tablename__ = "venta"
    id = Column(Integer , primary_key=True)
    date = Column(String,nullable=True)
    product_id = Column(Integer,nullable=True)
    country = Column(String,nullable=True)
    gender = Column(String,nullable=True)
    size = Column(String,nullable=True)
    price = Column(String,nullable=True)

    def __repr__(self): # Método informativo
        return f"Producto ID {self.product_id} del país {self.country},
género {self.gender} \
        \n tamaño {self.size}, precio {self.price} en la fecha
{self.date}"

####### Funciones #######

# Función READ_DB: Para leer la base de datos ventas_calzado.db y
organizar los datos.
def read_db(limit=10):

    # Crear la sesión
    Sesion = sessionmaker(bind=engine)
    sesion = Sesion()

    # Buscar todas las ventas
    query = sesion.query(Ventas)

    # Aplica el limite si está definido
    if limit > 0:
        query1 = query.limit(limit)

    # Leer una venta a la vez e imprime en pantalla
    print("Estos son los primeros 10 datos de la tabla ORIGINAL")
    for venta in query1:
        print(venta)

    nro_filas=query.count()
    print("La tabla ORIGINAL tiene",nro_filas,"filas.") #14967

    # Se eliminan las filas que tengan un valor nulo
    print("\n")
    print("Removiendo filas con valores vacíos...")
    print("\n")

    # Estas son las filas con valores nulos.
    query2 = sesion.query(Ventas).filter(
        (Ventas.date == "") |
        (Ventas.product_id == "") |
```

```
        (Ventas.country == "") |
        (Ventas.gender == "") |
        (Ventas.size == "") |
        (Ventas.price == "")
        )
    nro_filas2 = query2.count()
    print("Se eliminaran",nro_filas2,"filas de la tabla por datos
faltantes") #120
    print("\n")

    # Se procede a borrar las filas mencionadas.
    sesion.query(Ventas).filter(
        (Ventas.date == "") |
        (Ventas.product_id == "") |
        (Ventas.country == "") |
        (Ventas.gender == "") |
        (Ventas.size == "") |
        (Ventas.price == "")
        ).delete()

    sesion.commit() # Para guardar los cambios.

    # Se vuelve a hacer la consulta para ver la tabla filtrada
    query = sesion.query(Ventas)

    # Aplica el limite si está definido
    if limit > 0:
        query1 = query.limit(limit)

    print("Estos son los primeros 10 datos de la tabla FILTRADA")
    for venta in query1:
        print(venta)
    nro_filas3 = query.count()
    print("Quedan",nro_filas3,"filas en la tabla.") #14847

    query3 = sesion.query(Ventas)
    country = np.array([])
    gender = np.array([])
    size = np.array([])
    price = np.array([])

    for i in query3:
        country = np.append(country, i.country)
        gender = np.append(gender,i.gender)
        size = np.append(size,i.size)
        price_str = " ".join(i.price)
        price_i = float(re.sub(r'[^\d\-.]', '', price_str)) # Sacar $ y
pasar a float
        price = np.append(price,price_i)
```

```
    return country, gender, size, price

# Función PAÍSES ÚNICOS: Para ver en qué países hubo ventas:
def paises_unicos(country):

    paises_unicos = np.unique(country)
    print(paises_unicos)

def ventas_pais(countries, country, price):

    # Crear unas máscaras para obtener los índices del array
    # que corresponden a los paises
    mask_0 = country == countries[0] #"Canada"
    mask_1 = country == countries[1] #"Germany"
    mask_2 = country == countries[2] #"United States"
    mask_3 = country == countries[3] #"United Kingdom"

    # Utilizo las máscaras para acceder a los indices del array price
    # que corresponden a cada pais
    ventas_canada = price[mask_0]
    ventas_germany = price[mask_1]
    ventas_united_states = price[mask_2]
    ventas_united_kingdom = price[mask_3]

    suma_canada = np.sum(ventas_canada)
    suma_germany = np.sum(ventas_germany)
    suma_united_states = np.sum(ventas_united_states)
    suma_united_kingdom = np.sum(ventas_united_kingdom)

    Countries_dict = {}
    Countries_dict.update({ countries[0]: suma_canada, countries[1]:
suma_germany, countries[2]: suma_united_states, countries[3]:
suma_united_kingdom})

    return(Countries_dict)

# Función CALZADO PAÍS: Para ver qué tamaño fue el más vendido en cada
país.
def calzado_pais(countries, country, size):

    # Crear unas máscaras para obtener los índices del array
    # que corresponden a los paises
    mask_0 = country == countries[0] #"Canada"
    mask_1 = country == countries[1] #"Germany"
    mask_2 = country == countries[2] #"United States"
    mask_3 = country == countries[3] #"United Kingdom"

    # Utilizo las máscaras para acceder a los indices del array size
```

```
    # que corresponden a cada pais
    tamaño_canada = size[mask_0]
    tamaño_germany = size[mask_1]
    tamaño_united_states = size[mask_2]
    tamaño_united_kingdom = size[mask_3]

    sizes_canada = np.unique(tamaño_canada,return_counts=True)
    sizes_germany = np.unique(tamaño_germany,return_counts=True)
    sizes_united_states =
np.unique(tamaño_united_states,return_counts=True)
    sizes_united_kingdom =
np.unique(tamaño_united_kingdom,return_counts=True)


    mask_mas_vendido_C = sizes_canada[1] == max(sizes_canada[1])
    tamaño_mas_vendido_C = sizes_canada[0][mask_mas_vendido_C]
    tamaño_mas_vendido_C = " ".join(tamaño_mas_vendido_C .tolist()) # Con
tolist() se remuev el dtype y con el join se pasa de lista a str
    mask_mas_vendido_G = sizes_germany[1] == max(sizes_germany[1])
    tamaño_mas_vendido_G = sizes_germany[0][mask_mas_vendido_G]
    tamaño_mas_vendido_G = " ".join(tamaño_mas_vendido_G .tolist())
    mask_mas_vendido_USA = sizes_united_states[1] ==
max(sizes_united_states[1])
    tamaño_mas_vendido_USA = sizes_united_states[0][mask_mas_vendido_USA]
    tamaño_mas_vendido_USA = " ".join(tamaño_mas_vendido_USA .tolist())
    mask_mas_vendido_UK = sizes_united_kingdom[1] ==
max(sizes_united_kingdom[1])
    tamaño_mas_vendido_UK = sizes_united_kingdom[0][mask_mas_vendido_UK]
    tamaño_mas_vendido_UK = " ".join(tamaño_mas_vendido_UK .tolist())

    Sizes_dict = {}
    Sizes_dict.update({ countries[0]: tamaño_mas_vendido_C, countries[1]:
tamaño_mas_vendido_G, countries[2]: tamaño_mas_vendido_USA, countries[3]:
tamaño_mas_vendido_UK})

    return(Sizes_dict)

# Función VENTAS GENERO PAÍS: Para ver qué genero compro la mayor
cantidad de calzado en cada país.
def ventas_genero_pais(countries, gender_target, country, gender):

    generos_unicos = np.unique(gender) # "Female", "Male" y "Unix"

    # Crear unas máscaras para obtener los índices del array
    # que corresponden a los paises
    mask_0 = country == countries[0] #"Canada"
    mask_1 = country == countries[1] #"Germany"
    mask_2 = country == countries[2] #"United States"
    mask_3 = country == countries[3] #"United Kingdom"
```

```
    # Utilizo las máscaras para acceder a los indices del array size
    # que corresponden a cada pais
    genero_canada = gender[mask_0]
    genero_germany = gender[mask_1]
    genero_united_states = gender[mask_2]
    genero_united_kingdom = gender[mask_3]

    gender_canada = np.unique(genero_canada,return_counts=True)
    gender_germany = np.unique(genero_germany,return_counts=True)
    gender_united_states =
np.unique(genero_united_states,return_counts=True)
    gender_united_kingdom =
np.unique(genero_united_kingdom,return_counts=True)


    mask_target_C = gender_canada[0] == gender_target
    genero_target_C = gender_canada[1][mask_target_C]
    genero_target_C = genero_target_C .tolist()[0] # Con tolist() se
remuev el dtype y con el [0] se obtiene el unico elemento de la lista.
    mask_target_G = gender_germany[0] == gender_target
    genero_target_G = gender_germany[1][mask_target_G]
    genero_target_G = genero_target_G .tolist()[0]
    mask_target_USA = gender_united_states[0] == gender_target
    genero_target_USA = gender_united_states[1][mask_target_USA]
    genero_target_USA = genero_target_USA .tolist()[0]
    mask_target_UK = gender_united_kingdom[0] == gender_target
    genero_target_UK = gender_united_kingdom[1][mask_target_UK]
    genero_target_UK = genero_target_UK .tolist()[0]

    Target_Genre_dict = {}
    Target_Genre_dict.update({ countries[0]: genero_target_C,
countries[1]: genero_target_G, countries[2]: genero_target_USA,
countries[3]: genero_target_UK})

    return(Target_Genre_dict)




######## Bloque principal del programa #######

if __name__ == "__main__":

    data = read_db()
    country = data[0]
    gender = data[1]
    size = data[2]
    price = data[3]
```

```
    countries = ["Canada","Germany","United States", "United Kingdom"]
    gender_target = "Male" # Las opciones a analizar son: "Female",
"Male" y "Unix"
    print("En el siguiente array se muestran los países en los que hubo
ventas:")
    paises_unicos(country)

    print("En el siguiente diccionario se muestra el total de ventas por
país:")
    print(ventas_pais(countries, country, price))

    print("En el siguiente diccionario se muestra el tamaño de calzado
más vendido en cada país:")
    print(calzado_pais(countries, country, size))

    print("En el siguiente diccionario se muestan las ventas para el
género "+ gender_target+ " en cada país:")
    print(ventas_genero_pais(countries, gender_target, country, gender))

    print("Termine! Que buen programa soy ^^")
```

```
##########################################################################

# Proyecto Final - Inove Escuela de Código
# Tema Elegido: Python Analytics

# Alumno: Valentín Imperio.
# Versión: 1.0
# Profesores: Johana Rangel y Julián Salinas.
# Curso: Programador Python.
# Fecha de Entrega: 28/01/2023

# ARCHIVO BONUS: GRAFICOS.PY

##########################################################################

#### Librerías utilizadas ###

import matplotlib.pyplot as plt
import numpy as np
from main import read_db, ventas_pais, calzado_pais, ventas_genero_pais

# GRAFICOS DEL PROYECTO #

# Gráfico para Ventas por país
```

```
def grafico_ventas(countries, country, price):
    dict = ventas_pais(countries, country, price)

    def func(pct, allvals):
        absolute = int(np.round(pct/100.*np.sum(allvals)))
        return "{:.1f}%\n({:d} $)".format(pct, absolute)

    X = list(dict.values())
    Y = dict.keys()

    # Creo mi paleta de colores:
    colors = ["#7FFFD4","#13EAC9","#04D8B2","#008080"]
    fig = plt.figure()
    fig.suptitle("Ventas de calzado por país", fontsize = 16, weight =
"bold")
    ax = fig.add_subplot()
    ax.pie(X, labels=Y, colors = colors,  autopct=lambda pct: func(pct,
X), wedgeprops={'linewidth': 3.0, 'edgecolor': 'white'})
    ax.set_title("En Dólares [$]", fontsize = 12)
    ax.axis("equal")
    plt.show()

# Gráfico para N° de calzado por país

def grafico_calzado(countries, country, size):
    dict = calzado_pais(countries, country, size)

    X = list(dict.keys())
    Y = [float(x) for x in list(dict.values())]

    fig = plt.figure()
    ax = fig.add_subplot()
    ax.bar(X,Y, color="tab:purple", label="Países")
    ax.set_title("Tamaño de calzado más vendido en cada país ", fontsize
= 10, weight = "bold")
    ax.set_ylabel(" Tamaño (N° de calzado) ")
    ax.set_xlabel(" Países ")
    ax.legend()
    plt.xticks(X)
    plt.ylim(top=10)
    plt.show()

# Gráfico para cantidad de ventas por genero elegido para cada país

def grafico_genero_pais(countries, gender_target, country, gender):

    dict = ventas_genero_pais(countries, gender_target, country, gender)

    def func(pct, allvals):
```

```
        absolute = int(np.round(pct/100.*np.sum(allvals)))
        return "{:.1f}%\n({:d} u)".format(pct, absolute)

    X = list(dict.values())
    Y = dict.keys()

    # Creo mi paleta de colores:
    colors = ["#0343DF","#069AF3","#7BC8F6","#000080"]
    fig = plt.figure()
    fig.suptitle("Ventas de calzado para el genero "+gender_target+" por
país", fontsize = 16, weight = "bold")
    ax = fig.add_subplot()
    _, _, autotexts = ax.pie(X, labels=Y, colors =
colors,  autopct=lambda pct: func(pct, X), wedgeprops={'linewidth': 3.0,
'edgecolor': 'white'})
    for ins in autotexts:
        ins.set_color('white')
    ax.set_title("En pares [u]", fontsize = 12)
    ax.axis("equal")
    plt.show()


######## Bloque principal del programa #######

if __name__ == "__main__":

    data = read_db()
    country = data[0]
    gender = data[1]
    size = data[2]
    price = data[3]
    countries = ["Canada","Germany","United States", "United Kingdom"]
    gender_target = "Male" # Las opciones a analizar son: "Female",
"Male" y "Unix"

    grafico_ventas(countries, country, price)

    grafico_calzado(countries, country, size)

    grafico_genero_pais(countries, gender_target, country, gender)

    print("Termine! Que buen programa soy ^^")
```